

Zależności rankingowe w Beat Saber: Analiza statystyk graczy

Wiktor Piekarski
272726@student.pwr.edu.pl

9 czerwca 2024

Spis treści

1	Wstęp	1
2	Opis statystyk gracza	2
3	Zbiór danych i przetwarzanie	3
3.1	Zbiór danych	3
3.2	Przetwarzanie danych	3
3.3	Analiza danych	3
3.3.1	Przykładowe dane	3
3.3.2	Statystyki danych	4
3.3.3	Histogramy	4
3.3.4	Zależności między danymi	13
3.3.5	Wartości odstające	13
4	Dopasowywanie modeli do danych	13
4.1	Badanie zależności liniowych	13
4.2	Badanie zależności wielomianowych	21
4.3	Maszyna wektorów wspierających	34
5	Wnioski	35

1 Wstęp

Beat Saber to gra rytmiczna w wirtualnej rzeczywistości, wydana przez Czeskie studio deweloperskie Beat Games w 2018 roku. Akcja gry rozgrywa się w różnych surrealistycznych, neonowych środowiskach, a gracze przecinają bloki reprezentujące muzyczne bity za pomocą pary jasno kolorowych mieczy świetlnych.

Celem tego raportu jest zidentyfikowanie potencjalnych wzorców i trendów w relacji między pozycją w rankingu gracza a jego statystykami wyników w Beat Saber. Dzięki temu będzie można lepiej zrozumieć to, które statystyki najbardziej wpływają na pozycję w rankingu.

Analiza opiera się na danych zdobytych z platformy BeatLeader poprzez API. BeatLeader to nieoficjalna modyfikacja (mod) do Beat Saber'a stworzona przez społeczność gry. Mod ten polega na zbieraniu i wyświetlaniu wyników zagranych map¹ w postaci tablicy wyników widocznej w grze. BeatLeader prowadzi również własny ranking globalny graczy, który jest dostępny na stronie <https://beatleader.xyz/ranking/1>. Dodatkowo modyfikacja ta zbiera wiele statystyk dotyczących graczy i ich wyników, które będą wykorzystywane w tym raporcie.

Statystyki, które będą analizowane to: **ranga, liczba zagrań, najlepsze zagrane, średnia celność, obejrzone powtórki przez gracza, obejrzone powtórki przez innych, ranga krajowa,**

¹Mapa, często nazywana również poziomem, jest zestawem predefiniowanych sekwencji, które gracze muszą wykonać w rytm muzyki. Mapa określa układ i timing elementów, które gracz musi dotknąć, wcisnąć, przeciąć lub ominąć w zgodzie z tempem i melodią utworu muzycznego. W kontekście gier takich jak Beat Saber, mapa zawiera informacje o rozmieszczeniu bloków do przecięcia, ich kierunku oraz momencie, w którym pojawiają się w grze.

liczba najlepszych wyników, liczba poprawionych wyników, średnia ranga, maksymalna seria, zagrania SS+, zagrania SS, zagrania S+, zagrania S, zagrania A. Znaczenie tych statystyk jest szczegółowiej wytłumaczone poniżej. Dane zostały pobrane dla najlepszych 10000 graczy globalnie.

Każdy z wymienionych atrybutów może mieć wysokie powiązanie z pozycją w rankingu, a analiza tych danych może dostarczyć cennych informacji dla rankingowych graczy Beat Saber'a.

2 Opis statystyk gracza

- **Ranga (Rank):** Określa pozycję w rankingu gracza. Liczba naturalna większa niż 0.
- **Liczba zagrań (Total play count):** Określa całkowitą ilość zagranych map przez gracza. Liczba naturalna.
- **Najlepsze zagranie (Top pp):** Wartość pp najlepszego zagrań gracza. Pp oznacza "performance points", co można przetłumaczyć jako punkty wydajności. Jest to wartość dzięki której system ocenia jak "dobre" jest dane zagranie. Liczba rzeczywista dodatnia.
- **Średnia celność (Average accuracy):** Określa średnią celność gracza na wszystkich zagranych mapach. Celność w kontekście Beat Saber'a oznacza zdobyty procent maksymalnego wyniku. Przyjmuje wartość od 0.0 do 1.0.
- **Obejrzone powtórki przez gracza (Watched replays):** Określa liczbę obejrzanych powtórek przez gracza. BeatLeader automatycznie zapisuje powtórkę każdej zagranej mapy i każdy może ją zobaczyć w grze lub na stronie internetowej. Liczba naturalna.
- **Obejrzone powtórki przez innych (Replays watched):** Określa liczbę powtórek gracza, które zostały obejrzone przez innych graczy. Liczba naturalna.
- **Ranga krajowa (Country rank):** Określa pozycję w rankingu krajowym gracza. Liczba naturalna większa niż 0.
- **Liczba najlepszych wyników (Top 1 count):** Określa liczbę wyników, które są top 1 na mapach. Liczba naturalna.
- **Liczba poprawionych wyników (Total improvements count):** Określa całkowitą liczbę poprawionych wyników. Liczba naturalna.
- **Średnia ranga (Average rank):** Określa średnią rangę na mapach. Liczba rzeczywista większa lub równa 1.
- **Maksymalna seria (Max streak):** Długość najdłuższej serii trafiania bloczków za maksymalną ilość 115 punktów. Liczba naturalna.
- **Zagrania SS+ (SS+ plays):** Określa liczbę rankingowych zagrań "SS+", czyli zagrania z celnością w przedziale $> 95\%$. Liczba naturalna.
- **Zagrania SS (SS plays):** Określa liczbę rankingowych zagrań "SS", czyli zagrania z celnością w przedziale $90\% - 95\%$. Liczba naturalna.
- **Zagrania S+ (S+ plays):** Określa liczbę rankingowych zagrań "S+", czyli zagrania z celnością w przedziale $85\% - 90\%$. Liczba naturalna.
- **Zagrania S (S plays):** Określa liczbę rankingowych zagrań "S", czyli zagrania z celnością w przedziale $80\% - 85\%$. Liczba naturalna.
- **Zagrania A (A plays):** Określa liczbę rankingowych zagrań "A", czyli zagrania z celnością w przedziale $< 80\%$. Liczba naturalna.

3 Zbiór danych i przetwarzanie

3.1 Zbiór danych

Analizowane dane zostały pozyskane za pomocą API platformy BeatLeader używając modułu Requests w pythonie. Wielokrotnie użyto zapytania `"/players"` aby pobrać listę najlepszych graczy, oraz ich statystyki. W ten sposób zostały pobrane dane na temat 10000 najlepszych graczy w systemie BeatLeader, a następnie zapisane do pliku `beatleader_rawdata.json`, aby mogły być następnie użyte do analizy w projekcie.

3.2 Przetwarzanie danych

Po uzyskaniu danych, przeniesiono dane każdego gracza do jednej wielkiej tablicy, aby można było łatwiej pracować na danych. Następnie zostały usunięte zagnieżdżone słowniki przechowujące większość potrzebnych danych do analizy (`"scoreStats"`), a ich dane wyciągnięte na zewnątrz, aby był łatwiejszy dostęp. Wartości określające liczbę powtórek gracza, które zostały obejrzone przez innych graczy zalogowanych i niezalogowanych zostały zsumowane i połączone w jedną wartość. Niepotrzebne i niewykorzystane do analizy dane zostały usunięte, np. informacje o klanach, nazwa, zdjęcie profilowe, oraz wiele wartości, które przedstawiały dane bardzo podobne do tych, które zostały wybrane do analizowania. Na zakończenie przetwarzania wstępnego użyto metody `"info()"` z biblioteki Pandas, aby upewnić się, że analizowane dane będą pełne i nie występują wartości NULL, oraz usunięto dane kilku graczy, którzy mieli niedozwolone wartości atrybutów (np. Zagrania A: -1).

3.3 Analiza danych

3.3.1 Przykładowe dane

Ranga	1	266	7777	1729
Liczba zagrań	3053	575	137	857
Najlepsze zagranie	928.6394	617.6867	271.25266	452.5257
Średnia celność	0.9321346	0.95929354	0.8920867	0.8909242
Obejrzone powtórki przez gracza	1291	49	20	12
Obejrzone powtórki przez innych	50282	217	9	13
Ranga krajowa	1	9	542	694
Liczba najlepszych wyników	1099	24	4	1
Liczba poprawionych wyników	1337	367	92	380
Średnia ranga	8.10809	32.18087	300.61313	401.84482
Maksymalna seria	8	7	3	4
Zagrania SS+	602	91	17	4
Zagrania SS	101	10	42	202
Zagrania S+	15	0	19	189
Zagrania S	0	0	7	43
Zagrania A	0	0	5	12


Tabela 1: Przykładowy wycinek danych dla graczy kolejno: Bytesy, Vixoner, Veno, Meow9398

3.3.2 Statystyki danych


Atrybut	Wartość minimalna	Wartość maksymalna	Wartość średnia
Ranga	1	10000	5001.151861
Liczba zagrań	7	15842	477.858143
Najlepsze zagranie	180.860400	928.6394	387.010215
Średnia celność	0.272405	0.98993415	0.873561
Obejrzane powtórki przez gracza	0	13013	78.404662
Obejrzane powtórki przez innych	0	50282	142.763605
Ranga krajowa	1	3926	874.748499
Liczba najlepszych wyników	0	4894	13.852741
Liczba poprawionych wyników	0	3981	112.624750
Średnia ranga	1.061538	1424.4464	349.551294
Maksymalna seria	2	67	4.059424
Zagrania SS+	0	2104	36.561725
Zagrania SS	0	1154	62.128151
Zagrania S+	0	598	31.002201
Zagrania S	0	359	17.472789
Zagrania A	0	487	13.658563

Tabela 2: Wartości minimalne, maksymalne i średnie dla wszystkich atrybutów


3.3.3 Histogramy




Rysunek 1: Histogram rangi




Rysunek 2: Histogram liczby zagrań




Rysunek 3: Histogram najlepszych zagrań




Rysunek 4: Histogram średniej celności




Rysunek 5: Histogram obejrzanych powtórek przez gracza




Rysunek 6: Histogram obejrzanych powtórek przez innych




Rysunek 7: Histogram rangi krajowej




Rysunek 8: Histogram liczby najlepszych wyników




Rysunek 9: Histogram liczby poprawionych wyników




Rysunek 10: Histogram średniej rangi




Rysunek 11: Histogram maksymalnej serii




Rysunek 12: Histogram zagrań SS+




Rysunek 13: Histogram zagrań SS




Rysunek 14: Histogram zagrań S+





Rysunek 16: Histogram zagrań A

3.3.4 Zależności między danymi



Rysunek 17: Macierz korelacji zmiennych

Bazując na macierzy korelacji zmiennych widocznej wyżej stwierdzono, że ranga ma największe powiązanie z najlepszym zagranie, oraz najmniejsze powiązanie z zagraniami S. Liczba zagrań S ma na tyle znikomą korelację z rangą, że zostaje ona porzucona i nie będzie już analizowana w dalszej części raportu.

3.3.5 Wartości odstające


Analizując dane i histogramy, stwierdzono, że występuje wiele wartości odstających. Wszystkie mocno odstające dane zostały usunięte i nie będą brane pod uwagę w dalszej części projektu. Dane były uznawane za mocno odstające w sytuacji, gdy były oddalone o więcej niż 3 odchylenia standardowe od średniej.

4 Dopasowywanie modeli do danych


4.1 Badanie zależności liniowych

Została podjęta próba dopasowania zależności liniowych między rangą a innymi parametrami graczy. Poniższe wykresy przedstawiają różnorodne rezultaty: dla niektórych parametrów model liniowy wydaje się dobrze wpasowany, a dla innych zupełnie nie.


Dla każdego modelu liniowego obliczono współczynnik determinacji (R^2), średni błąd kwadratowy (MSE), oraz pierwiastek średniego błędu kwadratowego (RMSE) używając odpowiednich funkcji z modułu Scikit-learn. Obliczamy RMSE, ponieważ jest bardziej intuicyjny i łatwiejszy do interpretacji w praktyce, bo jest wyrażony w tych samych jednostkach co oryginalne dane.




Rysunek 18: Ranga a liczba zagrań




Rysunek 19: Ranga a najlepsze zagranie




Rysunek 20: Ranga a średnia celność




Rysunek 21: Ranga a obejrane powtórki przez gracza




Rysunek 22: Ranga a obejrzone powtórki przez innych




Rysunek 23: Ranga a ranga krajowa




Rysunek 24: Ranga a liczba najlepszych wyników




Rysunek 25: Ranga a liczba poprawionych wyników




Rysunek 26: Ranga a średnia ranga




Rysunek 27: Ranga a maksymalna seria




Rysunek 28: Ranga a zagrania SS+



Rysunek 29: Ranga a zagrania SS



Rysunek 30: Ranga a zagrania S+




Rysunek 31: Ranga a zagrania A

Atrybut	R^2	MSE	RMSE
Liczba zagrań	0.115	6521519.84	2553.73
Najlepsze zagrание	0.655	2540674.16	1593.95
Średnia celność	0.207	5846602.07	2417.97
Obejrzane powtórki przez gracza	0.0946	6672943.41	2583.2
Obejrzane powtórki przez innych	0.172	6104651.14	2470.76
Ranga krajowa	0.144	6312112.44	2512.39
Liczba najlepszych wyników	0.124	6456557.96	2540.98
Liczba poprawionych wyników	0.0564	6954620.19	2637.16
Średnia ranga	0.195	5931927.16	2435.55
Maksymalna seria	0.278	5320080.72	2306.53
Zagrania SS+	0.254	5497379.5	2344.65
Zagrania SS	0.338	4878990.63	2208.84
Zagrania S+	0.0419	7061384.4	2657.33
Zagrania A	0.0395	7079063.52	2660.65

Tabela 3: Parametry modelu liniowego dla atrybutów

4.2 Badanie zależności wielomianowych


W ramach analizy uogólnionego modelu liniowego (GLM) próbujemy dopasować zależności wielomianowe między statystykami graczy a ich pozycją w rankingu. Zbadano wielomiany stopnia: drugiego, trzeciego i czwartego. Dane zostały podzielone na część testową i treningową, używając metody "train_test_split" z modułu Scikit-learn. Dzięki temu unikamy problemu nadmiernego dopasowania, oraz zwiększy to ogólną jakość dopasowania modelu. Wyniki są interesujące, ponieważ wyraźnie wskazują na to, że tym większy stopień wielomianu, tym gorszy wynik MSE. Tradycyjny model liniowy wydaje się być lepiej dostosowany do analizowanych danych. Rezultaty znajdują się na wykresach i tabelkach poniżej.



Rysunek 32: Ranga a liczba zagrań

Model	R^2	MSE	RMSE
GLM2	-0.176	8970643.45	2995.1
GLM3	-0.203	9173709.48	3028.81
GLM4	-0.207	9203996.07	3033.81


Tabela 4: Statystyki liczby zagrań



Rysunek 33: Ranga a najlepsze zagrańie

Model	R^2	MSE	RMSE
GLM2	-0.662	12364250.6	3516.28
GLM3	-0.661	12352624.6	3514.63
GLM4	-0.659	12343214.0	3513.29


Tabela 5: Statystyki najlepszych zagrań



Rysunek 34: Ranga a średnia celność

Model	R^2	MSE	RMSE
GLM2	-0.197	8755518.46	2958.97
GLM3	-0.2	8781651.61	2963.39
GLM4	-0.201	8785993.08	2964.12


Tabela 6: Statystyki średniej celności



Rysunek 35: Ranga a obejrzone powtórki przez gracza

Model	R^2	MSE	RMSE
GLM2	-0.128	8271611.45	2876.04
GLM3	-0.14	8354530.42	2890.42
GLM4	-0.139	8347161.96	2889.15


Tabela 7: Statystyki obejrzanych powtórek przez gracza



Rysunek 36: Ranga a obejrzone powtórki przez innych

Model	R^2	MSE	RMSE
GLM2	-0.241	9087301.08	3014.52
GLM3	-0.259	9220223.71	3036.48
GLM4	-0.286	9416999.04	3068.71


Tabela 8: Statystyki obejrzanych powtórek przez innych



Rysunek 37: Ranga a ranga krajowa

Model	R^2	MSE	RMSE
GLM2	-0.211	9270072.54	3044.68
GLM3	-0.219	9333936.83	3055.15
GLM4	-0.266	9693071.35	3113.37


Tabela 9: Statystyki rangi krajowej



Rysunek 38: Ranga a liczba najlepszych wyników

Model	R^2	MSE	RMSE
GLM2	-0.163	8758333.61	2959.45
GLM3	-0.178	8874561.62	2979.02
GLM4	-0.178	8870635.19	2978.36


Tabela 10: Statystyki liczby najlepszych wyników



Rysunek 39: Ranga a liczba poprawionych wyników

Model	R^2	MSE	RMSE
GLM2	-0.0863	7941190.02	2818.01
GLM3	-0.0871	7947573.56	2819.14
GLM4	-0.0872	7947793.24	2819.18


Tabela 11: Statystyki liczby poprawionych wyników



Rysunek 40: Ranga a średnia ranga

Model	R^2	MSE	RMSE
GLM2	-0.203	8719967.91	2952.96
GLM3	-0.204	8724822.66	2953.78
GLM4	-0.204	8726756.84	2954.11


Tabela 12: Statystyki średniej rangi



Rysunek 41: Ranga a maksymalna seria

Model	R^2	MSE	RMSE
GLM2	-0.281	9564569.25	3092.66
GLM3	-0.286	9602412.59	3098.78
GLM4	-0.286	9602615.78	3098.81


Tabela 13: Statystyki maksymalnej serii



Rysunek 42: Ranga a zagrania SS+

Model	R^2	MSE	RMSE
GLM2	-0.326	9786805.35	3128.39
GLM3	-0.354	9998935.16	3162.11
GLM4	-0.374	10147241.3	3185.47


Tabela 14: Statystyki zagrań SS+



Rysunek 43: Ranga a zagrania SS

Model	R^2	MSE	RMSE
GLM2	-0.347	9974054.29	3158.17
GLM3	-0.367	10122720.3	3181.62
GLM4	-0.368	10130419.1	3182.83


Tabela 15: Statystyki zagrań SS



Rysunek 44: Ranga a zagrania S+

Model	R^2	MSE	RMSE
GLM2	-0.0173	7350120.68	2711.11
GLM3	-0.0307	7446659.18	2728.86
GLM4	-0.0482	7573056.4	2751.92

Tabela 16: Statystyki zagrań S+



Rysunek 45: Ranga a zagrania A

Model	R^2	MSE	RMSE
GLM2	-0.0562	7801563.85	2793.13
GLM3	-0.061	7836649.03	2799.4
GLM4	-0.0611	7837345.34	2799.53

Tabela 17: Statystyki zagrań A

4.3 Maszyna wektorów wspierających

Planujemy wykorzystać maszynę wektorów nośnych do regresji (SVR - Support Vector Regression). SVR to technika uczenia maszynowego, która wykorzystuje wektory nośne do przewidywania wartości numerycznych, w naszym przypadku estymacji pozycji w rankingu na podstawie innych statystyk graczy. Przed użyciem SVR, dokonano przeskalowania danych. Aby zapewnić odpowiednie działanie modelu, użyto klasy `StandardScaler` z pakietu `Scikit-learn`, która skaluje dane tak, aby miały średnią równą zero i odchylenie standardowe równe jeden. Dzięki temu każdy atrybut został dostosowany do jednolitej skali, co pomaga w utrzymaniu spójności i efektywności procesu uczenia modelu.

Dzięki modułowi `Scikit-learn` możemy skorzystać z gotowej implementacji SVR. Przeprowadzono testy SVR z różnymi kernelami i parametrami regularyzacji. Dane zostały podzielone na zestawy treningowe i testowe, co umożliwiło ocenę skuteczności modelu na nowych danych. Dla kernela liniowego (linear) wartość parametru C nie miała znaczącego wpływu na jakość predykcji w przeciwieństwie do innych kerneli, w których widać dużą zależność tego parametru do wartości MSE. Oznacza to, że model dobrze radził sobie z liniowymi zależnościami atrybutów.

Dla kernelów wielomianowego (polynomial) i RBF (Radial Basis Function - funkcja radialna) zauważono znaczącą poprawę wydajności modelu wraz ze zwiększeniem wartości parametru C . W szczególności dla RBF osiągnięto najniższy RMSE równy 1116.18 dla parametru C równym 10000. Wyniki te wskazują, że SVR z kernelami polynomial i RBF lepiej radzi sobie z nieliniowymi zależnościami w porównaniu do kernela linear. Maszyna wektorów nośnych okazała się również najlepszym z badanych modeli.

Dane SVR znajdują się w tabelce poniżej. Parametr γ jest istotny tylko dla kerneli nieliniowych, dlatego kernel liniowy ma wpisane wartości "-".

Kernel	Gamma	C	R^2	MSE	RMSE
Linear	-	10	-19.4	5232861.03	2287.54
Linear	-	100	-18.9	5088562.26	2255.78
Linear	-	1000	-18.9	5080349.89	2253.96
Linear	-	10000	-18.8	5079530.41	2253.78
Polynomial	scale	10	-51.4	13412193.1	3662.27
Polynomial	scale	100	-31.8	8388749.63	2896.33
Polynomial	scale	1000	-24.6	6547284.01	2558.77
Polynomial	scale	10000	-19.3	5196035.9	2279.48
Polynomial	auto	10	-50.5	13167527.6	3628.71
Polynomial	auto	100	-30.9	8161934.03	2856.91
Polynomial	auto	1000	-24.1	6432776.23	2536.29
Polynomial	auto	10000	-19.1	5151142.55	2269.61
RBF	scale	10	-37.7	9902694.49	3146.85
RBF	scale	100	-14.5	3963914.89	1990.96
RBF	scale	1000	-6.29	1866770.74	1366.3
RBF	scale	10000	-3.87	1245853.99	1116.18
RBF	auto	10	-37.9	9964945.76	3156.73
RBF	auto	100	-14.6	3998442.34	1999.61
RBF	auto	1000	-6.32	1872582.95	1368.42
RBF	auto	10000	-3.88	1249601.09	1117.86

Tabela 18: Dane z maszyny wektorów nośnych

5 Wnioski

Wszystkie trzy analizowane modele: liniowy, GLM i SVR, sugerują istnienie pewnej zależności między statystykami graczy Beat Saber'a, a ich pozycją w rankingu BeatLeader. Wyniki modeli wskazują, że istnieją pewne czynniki, które mają wpływ na to, jak dobrze gracze wypadają w rankingu. Niektóre atrybuty mają mocne powiązanie do rangi, a niektóre jedynie znikomą korelację. Najlepszym modelem dla badanych danych okazała się maszyna wektorów nośnych z najlepszym wynikiem RMSE równym 1116.18. Jednakże wynik ten nie jest wystarczająco dobry aby model mógł dokładnie przewidywać rangi graczy. Raport ten wciąż może być użyteczny dla graczy Beat Saber'a, ponieważ pokazuje on ciekawe korelacje między statystykami a rangą.